

공유오피스 3일 체험 결제 전환 예측 모델링 보고서

분석 목적

본 보고서는 공유오피스 3일 체험 신청자의 신청, 방문, 출입, 결제 데이터로 **체험 이후 결제 전환 여부를 예측하는 XGBoost 분류 모델**을 구축한 과정을 정리했습니다. 이 모델은 추후 마케팅 활동에서 결제 가능성이 높은 고객을 타겟팅하는 데 활용할 수 있습니다.

모델링 기준

- **Target:** is_payment — 결제 전환 여부 (결제: 1, 미결제: 0)
- **Model:** XGBoost Classifier
- **Validation 기준:** F1 Score 중심, Recall과 Precision 함께 확인
- **Test 기준:** 최종 선택된 피처와 threshold를 고정한 뒤 한 번만 평가

결제 전환 예측의 목적은 결제 가능성이 있는 고객을 넓게 포착하는 데 있으므로 Recall이 중요합니다. 다만 Recall만 높이면 미결제 고객까지 과도하게 결제 예상으로 분류할 수 있습니다. 그래서 Precision 값을 함께 보고 F1 Score를 기준으로 삼았습니다.

1. 데이터 개요

분석에는 아래 5개의 CSV 파일을 썼습니다.

데이터셋	행 수	설명
trial_register.csv	9,659	3일 체험 신청 정보 (신청일, 사용자 ID)
trial_visit_info.csv	11,477	방문 정보 (방문일, 체류시간, 첫/마지막 입퇴실)
trial_access_log.csv	63,708	출입 로그 (개별 입퇴실 기록)
trial_payment.csv	9,659	결제 여부
site_area.csv	9	지점 면적 정보

2. 탐색적 데이터 분석 (EDA)

2.1 결제자 / 미결제자 비율

전체 9,110명의 신청자 중 결제자는 3,425명(37.6%), 미결제자는 5,685명(62.4%)입니다. 클래스 불균형이 존재하므로 XGBoost 모델에 scale_pos_weight를 적용해 조정했습니다.

2.2 방문일수별 결제율

방문일수가 증가할수록 결제율이 전반적으로 상승하는 경향을 보입니다.

방문일수	인원	결제율
0일 (미방문)	3,087	35.2%
1일	2,709	31.3%
2일	1,932	42.0%
3일 이상	1,382	49.0%

2.3 결제자 vs 미결제자 행동 비교

주요 행동 지표의 평균값입니다.

지표	미결제	결제
방문일수	1.10일	1.33일
총출입횟수	6.83회	7.15회
신청 후 첫방문까지 일수	0.22일	0.31일

3. 피처 엔지니어링

모델 학습에 쓸 후보 피처 9개를 생성했습니다.

- **신청요일**: 체험 신청 요일 (0=월요일 ~ 6=일요일)
- **방문일수**: 3일 체험 기간 중 실제 방문한 날 수
- **일평균체류시간**: 일일 평균 체류시간 (시간 단위)
- **총체류시간**: 전체 체류시간 (시간 단위)
- **총출입횟수**: 전체 출입 횟수
- **주말방문포함**: 주말 방문 여부 (0 또는 1)
- **신청후첫방문일수**: 신청 후 첫 방문까지의 일수
- **방문여부**: 체험 기간 중 방문 여부 (0 또는 1)
- **방문당체류시간**: 방문일수로 나눈 평균 체류시간

미방문자나 데이터가 없는 경우는 -1로 처리해 모델이 이를 구분할 수 있도록 설계했습니다.

4. 피처 분석

4.1 피처-타겟 상관관계

결제 전환과의 상관관계 순위 (상위 5개):

피처	상관계수
방문일수	0.0891
신청후첫방문일수	0.0410
방문여부	0.0355
주말방문포함	0.0338
총출입횟수	0.0182

피처 간 상관계수가 전반적으로 낮아 단순한 선형 관계만으로는 설명하기 어려웠습니다. 비선형 관계와 변수 간 상호작용을 잘 포착하는 XGBoost를 사용했습니다.

5. 모델 개발 프로세스

5.1 데이터 분할

전체 9,110명의 데이터를 다음과 같이 분할했습니다.

- **Train:** 60% (5,466명) — 모델 학습
- **Valid:** 20% (1,822명) — 하이퍼파라미터 튜닝 및 피처 선택
- **Test:** 20% (1,822명) — 최종 모델 평가

5.2 XGBoost 모델 구성

파라미터	값	설명
n_estimators	100	부스팅 라운드 수
max_depth	3	트리 깊이 (과적합 방지)
learning_rate	0.02	학습률 (안정적 수렴)
subsample	0.8	샘플 서브샘플링 비율
colsample_bytree	0.8	피처 서브샘플링 비율
scale_pos_weight	계산됨	불균형 데이터 가중치 (neg_count/pos_count)

5.3 Threshold 최적화

기본 threshold 0.5 대신 프로젝트 목표(결제 가능성 있는 고객을 넓게 포착)에 맞춰 여러 threshold를 평가했습니다.

Threshold	Accuracy	Precision	Recall	F1 Score
0.35	0.3771	0.3762	0.9985	0.5465
0.40	0.4138	0.3874	0.9620	0.5524
0.45	0.4352	0.3896	0.8861	0.5412
0.50	0.6015	0.4622	0.3664	0.4088

5.4 Ablation Test (피처 중요도 검증)

피처를 하나씩 제거해 성능 변화를 측정했습니다. 각 피처의 중요성은 아래와 같습니다.

제거된 피처	F1 Score	성능 변화
전체 피처 (기준)	0.5524	—
일평균체류시간 제거	0.5543	+0.19% (오히려 개선)
신청요일 제거	0.5538	+0.14%
방문일수 제거	0.5501	-0.23% (가장 중요)
신청후첫방문일수 제거	0.5516	-0.08%
총출입횟수 제거	0.5516	-0.08%

5.5 전체 피처 조합 분석

9개 피처의 모든 조합($2^9 - 1 = 511$ 개)을 평가해 최적의 피처 세트를 찾았습니다. 상위 5개 조합입니다.

피처 조합	개수	Threshold	F1 Score
방문일수 + 총출입횟수 + 신청후첫방문일수	3	0.45	0.5550
방문일수 + 일평균체류시간 + 총체류시간 + 총출입횟수	4	0.40	0.5544
신청요일 + 방문일수 + 총체류시간 + 총출입횟수 + 주말방문포함 + 신청후첫방문일수 + 방문여부 + 방문당체류시간	8	0.40	0.5543
방문일수 + 일평균체류시간 + 총체류시간 + 총출입횟수 + 주말방문포함 + 신청후첫방문일수	6	0.40	0.5538
신청요일 + 방문일수 + 일평균체류시간 + 총체류시간 + 신청후첫방문일수	5	0.40	0.5528

최종 선택은 방문일수, 총출입횟수, 신청후첫방문일수 3개 피처입니다. 가장 적은 피처로 가장 높은 F1 Score 0.5550을 기록했으며, 피처 수가 적어 모델을 해석하고 실무에 적용하기에도 단순한 구성이었습니다.

5.6 최종 모델 성능 평가

Train+Valid 데이터로 재학습한 최종 모델의 Test 성능:

지표	값
Accuracy	0.4259
Precision	0.3878
Recall	0.9109
F1 Score	0.544
ROC-AUC	0.5862

혼동행렬 (Test 데이터):

	예측 미결제(0)	예측 결제(1)
실제 미결제(0)	152	985
실제 결제(1)	61	624

해석: Recall이 91.1%로 높아 결제 가능성이 있는 고객을 대부분 포착할 수 있습니다. 반면 Precision은 38.8%로, 예측 대상 중 실제 미결제 고객도 상당수 포함됩니다. 따라서 전체 고객에게 동일한 마케팅을 적용하기보다, 예측 확률이 높은 고객을 우선 선별해 인센티브를 집중하는 전략을 고려할 수 있습니다.

6. 주요 발견사항

- 방문일수: 결제 전환을 예측하는 데 가장 영향력이 높은 변수로 나타났습니다.
- 첫 방문 시점: 신청 후 첫 방문까지의 시간이 결제 전환 예측에 활용되는 행동 신호로 나타났습니다.
- 총출입횟수: 사용자의 이용 빈도를 나타내는 변수로, 결제 전환 예측에 활용할 수 있습니다.

7. 모델 활용

이 모델은 다음과 같은 마케팅 활동에 쓸 수 있습니다.

- 체험 기간 중 행동 데이터를 기반으로 결제 가능성 예측
- 예측 확률이 높은 고객을 우선적으로 선별
- 고객별 예측 점수를 활용한 타겟 마케팅
- 예측 점수를 마케팅 자동화 시스템과 연계

8. 결론

XGBoost 분류 모델을 활용해 3일 체험 신청자의 결제 전환 가능성을 예측했습니다. 최종 모델은 Recall 91.1%로 실제 결제 고객을 대부분 포착했으며, 방문일수, 신청 후 첫 방문까지의 시간, 총출입횟수 등의 행동 데이터가 예측에 활용될 수 있음을 확인했습니다.

다만 Precision이 38.8%로 미결제 고객도 함께 예측되므로, 전체 고객에게 동일하게 마케팅하기보다 예측 확률이 높은 고객을 우선 선별하는 방식으로 활용할 수 있습니다.

9. Streamlit 배포

본 분석의 결과물은 Streamlit 대시보드 형태로 배포했습니다. 여기서 고객의 결제 가능성을 실시간으로 예측하고 모니터링할 수 있습니다.

대시보드 링크: <https://payment-conversion-prediction-kfmzlsbdapywsfresbxfkm.streamlit.app/>